



PROPUESTAS DE TFM — MÁSTER EN DATA SCIENCE E IA (EBIS)

Sector: Financiero y Bancario

Objetivo de la etapa: Lluvia de ideas, análisis de viabilidad técnica y selección de propuesta para la Fase 1.




Resumen Ejecutivo y Criterios de Selección

Para asegurar el éxito del TFM compaginándolo con la jornada laboral hasta **febrero**, todas las propuestas cumplen tres condiciones indispensables:

- 1. Acceso a datos garantizado y gratuito:** Ninguna propuesta depende de pagos, APIs de suscripción ni datos confidenciales.
- 2. Núcleo sólido de Data Science & Machine Learning:** El corazón del proyecto es el tratamiento estadístico y el modelado predictivo, usando la IA Generativa como un complemento de alto valor (explicabilidad y reportes automáticos)

PROPUESTA 1: Motor Predictivo Híbrido de Mercados Financieros (Series Temporales + Sentimiento de Noticias con Scraper)



Arquitectura integral del sistema: flujo de ingesta multimodal, alineación temporal asíncrona (Point-in-Time) y modelado predictivo de intervalos mediante regresión cuantílica paralela.

1. Resumen Ejecutivo y Criterios de Selección

El presente Trabajo Fin de Máster (TFM) para el Máster en Data Science e Inteligencia Artificial (EBIS) propone el desarrollo de un Motor Predictivo Híbrido de Mercados

Financieros. Para garantizar el éxito del proyecto y su compatibilidad con la jornada laboral hasta febrero, esta propuesta cumple dos condiciones indispensables:

1. Acceso a datos garantizado y gratuito: El proyecto no depende de pagos, APIs de suscripción ni datos confidenciales.
2. Núcleo sólido de Data Science & Machine Learning: El corazón del sistema es el modelado estadístico, utilizando la Inteligencia Artificial (como el Procesamiento de Lenguaje Natural) como un complemento para extraer sentimiento y proporcionar explicabilidad.

2. El Concepto y la Pregunta Central

El ecosistema financiero asimila información a velocidades extremas. El análisis clásico basado solo en números suele fallar ante noticias imprevistas. Por tanto, la pregunta de negocio que guía esta investigación es:

«¿Podemos anticipar cambios de tendencia o picos de volatilidad en las acciones de los Gigantes Bancarios de EE.UU (el mercado estadounidense cuenta con muchos más datos que el español o europeo) combinando el histórico de precios con el análisis del tono de las noticias del día antes de la apertura del mercado?»

- **Usuario final en el banco:** Gestores de carteras de inversión, mesas de tesorería y analistas de banca privada (o sistemas automatizados *Robo-Advisors*).

3. El Problema de Negocio y el Retorno de Inversión (ROI)

- **El fallo del análisis clásico:** Los gráficos e indicadores técnicos tradicionales son "ciegos". No ven venir noticias imprevistas, escándalos corporativos o cambios regulatorios de última hora (fenómenos conocidos como *Cisnes Negros*).
- **El ROI a presentar:** El sistema *«permite a los gestores institucionales cubrir posiciones de riesgo (hedging) o rebalancear carteras automáticamente antes de que el mercado abra y reaccione bruscamente»*.

4. Origen Exacto de los Datos (100% Gratuitos)

El proyecto requiere la fusión de dos mundos heterogéneos: números (rama cuantitativa) y texto (rama cualitativa). Ambas fuentes están totalmente validadas.

4.1. Rama Cuantitativa (Precios e Indicadores)

A) Se utilizará la API pública de Yahoo Finance en Python ([yfinance](https://ranaroussi.github.io/yfinance/), <https://ranaroussi.github.io/yfinance/>).

- Datos: Cotizaciones históricas diarias e intradiarias (Apertura, Cierre, Máximo, Mínimo, Volumen) de los últimos 5-10 años.
- Universo de Activos: Gigantes bancarios como JPMorgan Chase (JPM), Bank of America (BAC), Wells Fargo (WFC), Goldman Sachs (GS), Morgan Stanley (MS) y Citigroup (C).

- Detalle técnico: Se utilizará el parámetro `auto_adjust=True` en la descarga. Esto es vital para que los precios se corrijan automáticamente ante eventos como divisiones de acciones (*splits*) o dividendos, evitando que el modelo confunda un ajuste contable con un desplome del mercado.

B) Datos para ver la situación macroeconómica de la Federal Reserve Economic Data (FRED)

A revisar ya que algunos datos pueden ser relevantes ya que da mucho contexto de lo que ocurre a nivel macro en la economía estadounidense y esto tiene impacto directo sobre todos los bancos y sectores del país

<https://fred.stlouisfed.org/docs/api/fred/>

4.2. Rama Cualitativa (Noticias e Inteligencia de Mercado)

Para que la máquina "lea" las noticias, dividiremos el trabajo en dos etapas:

A) Entrenamiento Histórico (Dataset FNSPID): Para entrenar el modelo con años de historia, usaremos un inmenso archivo de 22 GB disponible en HuggingFace (https://huggingface.co/datasets/Zihan1004/FNSPID/resolve/main/Stocknews/nasdaq_external_data.csv) que contiene noticias financieras desde 1999 hasta 2023. Este archivo se filtrará exhaustivamente para procesar solo a las empresas objetivo (para no malgastar recursos computacionales). Las columnas clave son:

- `Date`: Marca temporal UTC exacta (fundamental para sincronizar datos).
- `Stock_symbol`: Ticker del activo (ej. JPM, BAC).
- `Article_title` y `Article`: Cuerpo íntegro para analizar el sentimiento.
- `Url` y `Publisher`: Fuente de origen (Bloomberg, Reuters, etc.).

Optimización de recursos e ingesta: Dado que el dataset global contiene miles de compañías del mercado estadounidense, la ingesta no cargará el archivo íntegro en memoria RAM. Se aplicará una lectura por bloques (*chunking* mediante DuckDB o Polars) filtrando en streaming exclusivamente por los 6 tickers bancarios (`JPM`, `BAC`, `WFC`, `C`, `GS`, `MS`). Esto reduce el volumen efectivo de procesamiento de 22 GB a menos de 1 GB, haciendo viable la inferencia local de FinBERT en tiempos de cómputo razonables sin requerir infraestructura cloud de alto coste

B) Ingesta de Prensa en Vivo (Web Scraping): Para la predicción en tiempo real (producción), usaremos un motor de Web Scraping Distribuido (código disponible en: <https://github.com/ArturoCarrilloJimenez/WebScrapingDistributed>). Este sistema atacará portales económicos abiertos como:

- Sitemaps de Benzinga (https://www.benzinga.com/sitemap_index.xml).
- Feeds RSS de Yahoo Finance (<https://finance.yahoo.com/rss/headline?s=>).
- Comunicados corporativos de Business Wire.

Para evitar procesar noticias repetidas (ruido mediático), el scraper usará una técnica matemática llamada MinHash, que detecta y descarta artículos casi idénticos compartidos

por diferentes agencias de prensa, reduciendo drásticamente la carga de procesamiento (pendiente de investigar, esto es sugerencia de la ia).

C) Eventos Regulatorios Oficiales (SEC EDGAR)

El sistema consultará informes oficiales del gobierno de EE.UU. a través de la API REST pública de la SEC (<https://www.sec.gov/edgar/sec-api-documentation>). Los datos se piden usando el número identificador "CIK" de cada empresa:

- JPMorgan Chase: [CIK0000019617](#)
- Bank of America: [CIK0000070858](#)
- Wells Fargo: [CIK0000072971](#)
- Citigroup: [CIK0000831001](#)
- Goldman Sachs: [CIK0000886982](#)
- Morgan Stanley: [CIK0000895421](#)

Nota de viabilidad: Para respetar la Política de Acceso Justo (*Fair Access Policy*), el programa limitará las peticiones a un máximo de 10 por segundo e inyectará una cabecera [User-Agent](#) declarando nuestro email, evitando cualquier tipo de bloqueo institucional.

5. Entradas (Inputs) vs. Salidas (Outputs)

Para evitar la trampa habitual de intentar adivinar precios absolutos en euros o dólares —un error clásico que invalida los modelos por falta de estacionariedad—, el sistema se enfoca en estimar el comportamiento relativo y el riesgo de la siguiente jornada de mercado:

- Entradas (Inputs):
 - Rama Cuantitativa (Datos Técnicos de Mercado): Variaciones porcentuales de sesiones previas, indicadores de momentum (RSI), medias móviles y volatilidad histórica rezagada de los activos bancarios analizados, extraídos de Yahoo Finance.
 - Rama Cualitativa (Señales de Información Exógena): Puntuación numérica continua de sentimiento (escalada entre -1 para pánico/muy negativo y +1 para optimismo/muy positivo) extraída de noticias y hechos relevantes de la SEC, junto con el volumen de cobertura mediática y un factor de atenuación temporal (*Sentiment Decay*).
- Salidas (Outputs):
 - Rango porcentual esperado para la siguiente sesión ($t + 1$): Un intervalo dinámico de fluctuación con un nivel de confianza estadístico prefijado (por ejemplo, al 80% de confianza, predecir que el retorno de la acción se moverá entre $[-1.20\%, +0.75\%]$).
 - Volatilidad e incertidumbre condicional: La amplitud del rango predicho funciona como un termómetro de riesgo; a mayor dispersión entre el límite inferior y el superior, mayor es la probabilidad de que el mercado reaccione de forma abrupta a la apertura.

6. Tipos de Modelos

La arquitectura del sistema no depende de una única caja negra, sino de un pipeline secuencial de dos modelos de Aprendizaje Supervisado (Supervised Learning) especializados:

Modelo 1: Modelo Cualitativo de Procesamiento de Lenguaje Natural (NLP / Transfer Learning)

- Tipo de modelo: Aprendizaje Supervisado basado en Transformers / *Transfer Learning* especializado en el dominio financiero (FinBERT).
- Entrada (X): Texto no estructurado en lenguaje natural (titulares y cuerpos de noticias económicas capturados por el *scraper* distribuido y comunicados oficiales urgentes Form 8-K de la SEC).
- Salida (Y): Vector estructurado de polaridad de sentimiento (puntuaciones normalizadas continuas de tono positivo, negativo o neutral) y métricas de relevancia textual.

Modelo 2: Modelo Cuantitativo Tabular y Temporal (Regresión Cuantílica)

- Tipo de modelo: Aprendizaje Supervisado de Regresión Cuantílica sobre Series Temporales (*Quantile Regression* implementada sobre modelos de árboles de decisión como LightGBM o XGBoost, optimizados mediante la función de pérdida *Pinball Loss*).
- Entrada (X): Matriz tabular unificada que combina los indicadores técnicos del histórico de precios con las variables de sentimiento numéricas procesadas previamente por el Modelo 1.
- Salida (Y): Estimación simultánea de los límites inferior y superior de la distribución de retornos para la apertura siguiente (r_{t+1}), correspondientes a los percentiles objetivo (por ejemplo, percentil 10 y percentil 90 para garantizar una cobertura del 80%).

7. Problemas, Trampas a Resolver y Tecnologías Clave

La complejidad global del proyecto es de 8.0/10. Para que el TFM sea robusto ante un tribunal, superaremos tres grandes trampas de la industria financiera:

1. Data Leakage (Filtración del futuro): Es el error de hacer que el modelo "vea" noticias del futuro durante el entrenamiento. Las noticias publicadas un sábado deben aplicarse a la apertura del mercado del lunes. Sincronizar mal las horas invalida el modelo.
 - *Solución*: Usaremos la función de cruce temporal asíncrono (`merge_asof` en Python) programada estrictamente hacia atrás (`backward`), garantizando que cada cotización se empareje solo con noticias publicadas *antes* de ese instante.
2. Ruido del mercado y Validación de Intervalos: En la bolsa real nadie predice retornos puntuales continuos con precisión alta debido a la baja relación señal-ruido.
 - *Solución*: En lugar de forzar una clasificación binaria simplista, el éxito del modelo cuantitativo se auditará mediante:

- Calibración de la Cobertura Empírica: Garantizar que el retorno real caiga dentro del rango predicho $[\hat{y}_{0.10}, \hat{y}_{0.90}]$ en una tasa cercana al 80\% de las sesiones en datos no vistos (*out-of-sample*).
 - Minimización del *Pinball Loss* / *Winkler Score*: Penalizando tanto la amplitud excesiva del túnel predicho (falta de precisión) como las rupturas imprevistas de los límites ante eventos de alta volatilidad. Se utilizará el algoritmo Boruta para descartar variables de ruido antes de entrenar los estimadores cuantílicos en LightGBM/XGBoost.
3. Días sin noticias y "Sentiment Decay": ¿Qué pasa si una empresa no tiene noticias durante 4 días? Asumir que una noticia del lunes sigue impactando igual el jueves es un error.
- *Solución*: Implementaremos un algoritmo de "Decaimiento del Sentimiento" (basado en ecuaciones de vida media, $T_{1/2}$). Este modelo matemático atenuará el impacto numérico de una noticia a medida que pasen las horas, simulando cómo el mercado digiere la información.

Para traducir los textos a números (análisis de sentimiento), no usaremos modelos genéricos como ChatGPT, sino FinBERT. Este es un modelo de lenguaje especializado, entrenado por investigadores con el diccionario financiero, capaz de clasificar de forma barata y en milisegundos si un texto de la bolsa es positivo, negativo o neutral con una precisión sobresaliente.

8. Visión de las Siguientes Fases (Ruta a Febrero)

- **Octubre**: Extracción automatizada de noticias en vivo (despliegue del *scraper* distribuido) y descarga de series temporales históricas ajustadas con *yfinance*.
- **Noviembre**: Ingesta por *chunks* del histórico FNSPID filtrado a los 6 activos bancarios. Extracción por lotes de puntuaciones numéricas con FinBERT. Cálculo de indicadores técnicos y ejecución de cruce temporal asíncrono con *merge_asof* para garantizar cero *Data Leakage*.
- **Diciembre**: Selección de variables con Boruta y modelado predictivo mediante **Regresión Cuantílica con LightGBM y XGBoost** (*objective='quantile'*) optimizando *Pinball Loss* para percentiles 10 y 90. Calibración de la cobertura empírica (meta del 80%) y *backtesting* de una estrategia de gestión de riesgo dinámico (toma de coberturas y dimensionamiento de posición según la amplitud del túnel) frente a la estrategia pasiva de comprar y mantener (*Buy & Hold*). Integración de IA Explicable con **TreeSHAP** para auditar la atribución del sentimiento frente a métricas técnicas.
- **Enero-Febrero**: Desarrollo del *Dashboard* financiero interactivo en Streamlit (visualización de bandas cuantílicas de retorno y noticias superpuestas) y redacción final de la memoria del TFM.

9. Anexo de Viabilidad Legal, Ética y Cumplimiento Normativo (Compliance)

El desarrollo asume un diseño *Compliance-by-Design* amparado por los siguientes pilares:

1. Excepción Académica para Minería de Textos: El sistema de extracción (*scraper*) se acoge al Artículo 3 de la Directiva (UE) 2019/790 sobre derechos de autor, que permite explícitamente la minería de textos y datos (TDM) a instituciones con fines científicos o académicos.
2. Inferencia Efímera (Copyright y AI Act): El programa solo usará el texto en la memoria RAM para calcular un vector matemático (el score de sentimiento). El texto original protegido por derechos de autor será destruido de forma inmediata. No publicaremos artículos ajenos, solo metadatos numéricos.
3. Acceso Lícito y Muros de Pago: El orquestador descartará URLs bajo modelos de suscripción (*Paywalls*) y leerá los archivos `robots.txt` para respetar las políticas de cada medio.
4. Privacidad (Exención RGPD): El sistema analiza tendencias macroeconómicas de empresas (personas jurídicas) de los índices S&P500. Al no recopilar Información de Identificación Personal (PII) de personas físicas, el proyecto está al 100% exento de la aplicación de la ley de protección de datos europea (RGPD).

10. Fuentes de Información, Papers y Recursos de Aprendizaje

Categoría	Recurso / Referencia	Enlace (URL)	Para qué nos ayuda en el proyecto
Paper Académico	<i>FinBERT: A Pre-trained Financial Language Model for Financial Sentiment Analysis</i> (Yang et al., 2020)	arXiv:1908.10063	Fundamenta teóricamente la elección de FinBERT frente a BERT genérico para cuantificar sentimiento en informes bancarios.
Paper Académico	<i>Stock Market Prediction via Multi-Source Information Fusion</i> (Xu & Cohen, KDD 2018)	ACM Digital Library	Proporciona la arquitectura de referencia para fusionar series temporales numéricas con señales de texto dispersas en el tiempo.

Paper Académico	<i>When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks</i> (Loughran & McDonald, 2011)	SSRN Abstract 1334984	Justifica ante el tribunal por qué el vocabulario financiero corporativo requiere un tratamiento de NLP especializado y no generalista.
Paper Académico	<i>Can ChatGPT Forecast Stock Price Movements?</i> (Lopez-Lira & Tang, 2023)	arXiv:2304.07619	Sirve como benchmark y estado del arte para contrastar la predicción de retornos al día siguiente usando modelos de lenguaje sobre noticias.
Metodología Cuantitativa	<i>Advances in Financial Machine Learning</i> (Marcos López de Prado, 2018)	Wiley Library	Guía obligatoria para diseñar la validación temporal (<i>Purged K-Fold</i>), evitar el <i>data leakage</i> serial y formular variables estacionarias.
Metodología Cuantitativa	<i>Machine Learning for Algorithmic Trading - 2nd Edition</i> (Stefan Jansen)	GitHub Repository	Contiene implementaciones de referencia en Python para cruces de señales de NLP con XGBoost, backtesting y cálculo del <i>Information Coefficient</i> .

Dataset Histórico	<i>FNSPID (Financial News and Stock Price Integration Dataset)</i>	Hugging Face Datasets	Fuente primaria gratuita con más de 20 años de noticias etiquetadas por ticker para el entrenamiento y backtesting offline.
Datos Regulatorios	<i>SEC EDGAR Submissions & Company API Documentation</i>	SEC.gov API Docs	Especificación oficial para extraer eventos corporativos relevantes (8-K, 10-Q) mediante llamadas REST gratuitas asociadas a los CIK de los bancos.
Datos de Mercado	<i>yfinance Documentation (Ran Aroussi)</i>	yfinance Docs	Extracción automatizada del histórico de precios ajustados (<i>auto_adjust=True</i>) y volumen de los 6 activos bancarios seleccionados.
Modelo Pre-entrenado	<i>ProsusAI/finbert (Model Weights & Tokenizer)</i>	Hugging Face Hub	Modelo base descargable para ejecutar inferencia local (logits y scores de sentimiento -1 a +1) sin incurrir en costes de APIs externas.

Ingeniería de Datos	<i>Pandas merge_asof Specification (Point-in-Time Joins)</i>	Pandas Docs	Implementación técnica del emparejamiento temporal asíncrono para garantizar que ninguna noticia posterior a la apertura entre al modelo.
Competición de Referencia	<i>Two Sigma: Using News to Predict Stock Movements</i>	Kaggle Competition	Análisis de soluciones ganadoras sobre ingeniería de atributos temporales (<i>rolling aggregations</i> y decaimiento de noticias).
Explicabilidad (XAI)	<i>SHAP (SHapley Additive exPlanations) - TreeExplainer Docs</i>	SHAP Documentation	Implementación técnica de TreeSHAP para auditar qué peso tuvo el sentimiento frente a los indicadores técnicos en cada predicción de XGBoost.